

Approximation du Kernel exponentiel

May 9, 2026

1 Méthodes aléatoires

1.1 La décomposition Gaussienne

Les méthodes d'approximation des kernels sont souvent particulières aux kernels invariants par translation ou même plus spécifiquement au kernel gaussien. Ils sont définis ainsi :

Définition 1 (Kernel invariant par translation) *Un kernel $K : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ est dit invariant par translation (ou shift-invariant) s'il existe une fonction $k : \mathbb{R}^d \rightarrow \mathbb{R}$ telle que :*

$$K(x, y) = k(x - y), \quad \forall x, y \in \mathbb{R}^d.$$

Définition 2 (Kernel gaussien) *Le kernel gaussien est défini par :*

$$K_{\text{gauss}}(x, y) = \exp\left(-\frac{\|x - y\|^2}{2\sigma^2}\right),$$

pour un paramètre d'échelle $\sigma > 0$.

Le kernel gaussien est en particulier invariant par translation et possède une riche littérature associée. De plus, le kernel softmax (ou kernel exponentiel), défini par $\text{SM}(x, y) = \exp(x^\top y)$, peut s'exprimer en fonction du kernel gaussien de la manière suivante :

$$\text{SM}(x, y) = \exp\left(\frac{\|x\|^2}{2}\right) K_{\text{gauss}}(x, y) \exp\left(\frac{\|y\|^2}{2}\right).$$

Ainsi, toute approximation du kernel gaussien fournit directement une approximation du kernel softmax, à une renormalisation près.

Un théorème assez général justifie la diversité des méthodes associées à ce kernel.

Théorème 1 (Théorème de Bochner) *Un kernel continu $K(x, y) = k(x - y)$ invariant par translation est défini positif si et seulement si k est la transformée de Fourier d'une mesure de probabilité non négative $p(\omega)$ sur $\mathbb{R}^d$:*

$$k(\delta) = \int_{\mathbb{R}^d} e^{i\omega^\top \delta} p(\omega) d\omega = \mathbb{E}_{\omega \sim p} \left[e^{i\omega^\top \delta} \right].$$

Dans le cas du kernel gaussien, la mesure spectrale p est elle-même gaussienne : $p = \mathcal{N}(0, I_d)$.

Le théorème encourage fortement une méthode de Monte Carlo pour approcher les kernels. On peut construire un estimateur non biaisé à partir d'un tirage aléatoire de fréquences $\omega_1, \dots, \omega_m \stackrel{\text{iid}}{\sim} p$. Les méthodes principales seront listées dans la suite.

1.2 Random Fourier Features (RFF)

(Rahimi & Recht, 2007)

On tire m vecteurs $\omega_1, \dots, \omega_m \stackrel{\text{iid}}{\sim} \mathcal{N}(0, I_d)$ et on définit la carte de features aléatoires :

$$\phi(x) = \frac{1}{\sqrt{m}} (\cos(\omega_1^\top x), \sin(\omega_1^\top x), \dots, \cos(\omega_m^\top x), \sin(\omega_m^\top x)) \in \mathbb{R}^{2m},$$

de sorte que $K_{\text{gauss}}(x, y) \approx \phi(x)^\top \phi(y) = \frac{1}{n} \sum_{i=1}^n \cos([Zx]_i) \cos([Zy]_i)$.

Pour réduire la variance, on adapte le choix des ω_i grâce à la procédure d'orthonormalisation de Gram-Schmidt : on impose que les ω_i soient mutuellement orthogonaux tout en respectant marginalement la distribution $\mathcal{N}(0, I_d)$. C'est la méthode **Orthogonal Random Features (ORF)**.

1.3 Fastfood

(Le et al., 2013)

Cette méthode construit une approximation structurée des projections aléatoires en remplaçant la matrice gaussienne dense $W \in \mathbb{R}^{m \times d}$ par un produit de matrices creuses et de matrices de Hadamard :

$$W = \frac{1}{\sigma} SHGP HB,$$

où

- B : matrice diagonale de signes aléatoires
- P : permutation aléatoire
- G : matrice diagonale de coefficients gaussiens
- H : matrice de Walsh-Hadamard
- S : matrice de mise à l'échelle

Cette décomposition permet de calculer la transformation Wx en $\mathcal{O}(d \log d)$ au lieu de $\mathcal{O}(md)$, réduisant ainsi le coût computationnel tout en maintenant une bonne approximation du kernel.

1.4 SORF

(*Structured Orthogonal Random Features*, Yu et al., 2016) :

Comme Fastfood, SORF remplace la matrice gaussienne dense $W \in \mathbb{R}^{m \times d}$ par une décomposition structurée afin de réduire le coût de calcul à $\mathcal{O}(d \log d)$. La matrice est paramétrée sous la forme :

$$W = \frac{\sqrt{d}}{m} D_3 H D_2 H D_1,$$

où H est la matrice de Walsh-Hadamard et D_1, D_2, D_3 sont des matrices diagonales de signes aléatoires i.i.d. (± 1). Contrairement à Fastfood, il n'y a pas d'égalité exacte entre l'espérance de $WW^\top$ et la matrice identité : l'estimateur est légèrement biaisé, ce biais tendant vers 0 lorsque $d \rightarrow \infty$.

La méthode SORF admet une généralisation appelée **ROM** (*Random Orthogonal Matrices*, Choromanski et al., 2017), qui englobe SORF et d'autres constructions à base de matrices de Givens ou de Hadamard aléatoires dans un cadre théorique unifié. ROM garantit que les vecteurs ω_i ont bien une distribution marginale isotrope, ce qui assure l'existence d'estimateurs peu biaisés ou non biaisés du kernel gaussien

1.5 Performer

Les feature maps de la plupart des noyaux utilisés en pratique peuvent s'écrire sous la forme générale suivante :

$$\phi(x) = \frac{h(x)}{\sqrt{m}} \left(f_1(\omega_1^\top x), \dots, f_1(\omega_m^\top x), \dots, f_l(\omega_1^\top x), \dots, f_l(\omega_m^\top x) \right) \quad (1)$$

où $\omega_1, \dots, \omega_m$ sont des vecteurs aléatoires tirés d'une distribution isotrope (généralement une distribution gaussienne).

L'article présente alors deux fonctions ϕ distinctes, appelées *Positive Random Features* (PRFs), qui approximent fidèlement et sans biais le noyau softmax :

- SM_m^{d+} : où $h(x) = \exp(-\|x\|^2/2)$, $l = 1$, et $f_1(u) = \exp(u)$. Le feature map s'écrit alors :

$$\phi(x) = \frac{e^{-\|x\|^2/2}}{\sqrt{m}} \left(\exp(\omega_1^\top x), \dots, \exp(\omega_m^\top x) \right) \quad (2)$$

- $\text{SM}_m^{d\text{hyp}+}$: conçu pour réduire encore la variance, où $h(x) = \frac{1}{\sqrt{2}} \exp(-\|x\|^2/2)$, $l = 2$, avec $f_1(u) = \exp(u)$ et $f_2(u) = \exp(-u)$. Le feature map s'écrit :

$$\phi(x) = \frac{e^{-\|x\|^2/2}}{\sqrt{2m}} \left(\exp(\omega_1^\top x), \dots, \exp(\omega_m^\top x), \exp(-\omega_1^\top x), \dots, \exp(-\omega_m^\top x) \right) \quad (3)$$

Ces deux estimateurs sont non biaisés, c'est-à-dire que pour tout couple de vecteurs $x, y \in \mathbb{R}^d$:

$$\mathbb{E}[\langle \phi(x), \phi(y) \rangle] = \exp\left(\frac{x^\top y}{\sqrt{d}}\right) = \text{SM}(x, y) \quad (4)$$

Enfin, l'article affirme qu'il est important de choisir les échantillons $\omega_1, \dots, \omega_m$ de manière aléatoire et non biaisée, tout en forçant le fait qu'ils soient orthogonaux entre eux. Cette approche, appelée *Orthogonal Random Features* (ORFs), permet de réduire la variance de l'estimateur. En effet, en forçant l'orthogonalité, on évite que deux vecteurs ω_i et ω_j portent une information redondante, ce qui améliore la couverture de l'espace des fréquences. L'orthogonalisation est mathématiquement réalisée via la procédure de Gram-Schmidt : on tire m vecteurs gaussiens i.i.d., puis on les orthogonalise tout en préservant leur distribution marginale, de sorte que l'estimateur reste non biaisé. Les auteurs montrent que cette combinaison — PRFs avec ORFs — constitue le mécanisme **FAVOR+** (*Fast Attention Via positive Orthogonal Random features*), qui est au cœur de l'architecture Performer.

1.6 Random Feature Maps for Dot Product Kernels

L'article (*Kar & Karnick, 2012*) souhaite trouver une méthode semblable à celles destinées aux kernels shift-invariants pour les kernels définis par un produit scalaire, i.e. les kernels de la forme :

$$K(x, y) = f(\langle x, y \rangle), \quad x, y \in \mathbb{R}^d.$$

Il se repose sur le théorème suivant :

Théorème 2 (Caractérisation des kernels produit scalaire définis positifs)

Une fonction $f : \mathbb{R} \rightarrow \mathbb{R}$ définit un kernel défini positif $K : B_2(0, 1) \times B_2(0, 1) \rightarrow \mathbb{R}$ par $K(x, y) = f(\langle x, y \rangle)$ si et seulement si f est une fonction analytique admettant un développement de Maclaurin à coefficients non négatifs :

$$f(x) = \sum_{n=0}^{\infty} a_n x^n, \quad a_n \geq 0 \quad \forall n \geq 0.$$

L'idée de l'article est que les coefficients $(a_n)_{n \geq 0}$ peuvent être vus comme une mesure positive (avant normalisation) sur les entiers naturels. Donc, estimer $K(x, y) = \sum_{n=0}^{\infty} a_n \langle x, y \rangle^n$ revient à estimer chaque terme $a_n \langle x, y \rangle^n$ de manière aléatoire.

Néanmoins, les $(a_n)_{n \geq 0}$ convergent souvent lentement (queue polynomiale), ce qui implique des coûts en randomness prohibitifs pour estimer les termes d'ordre élevé. Les auteurs résolvent ce problème en imposant une distribution de probabilité à queue exponentielle sur $\mathbb{N}$ qui dépend d'un paramètre $p > 1$:

$$\mathbb{P}(N = n) = \frac{1}{p^{n+1}},$$

(un choix pratique est $p = 2$, qui définit bien une mesure de probabilité normalisée sur $\mathbb{N}$).

On tire alors N vecteurs de Rademacher indépendants $\omega_1, \dots, \omega_N \in \{-1, +1\}^d$ (chaque coordonnée tirée à pile ou face), et on définit la carte de features élémentaire :

$$Z : x \mapsto \sqrt{a_N p^{N+1}} \prod_{j=1}^N \omega_j^\top x.$$

de sorte que :

$$\mathbb{E} \left[\sqrt{a_N p^{N+1}} \prod_{j=1}^N \omega_j^\top x \cdot \sqrt{a_N p^{N+1}} \prod_{j=1}^N \omega_j^\top y \right] = \sum_{n=0}^{\infty} a_n \langle x, y \rangle^n = K(x, y).$$

L'estimateur est donc non biaisé pour $K(x, y)$.

Ainsi, l'approximation proposée (**Random Maclaurin Feature Maps**) est alors, pour D copies indépendantes $Z_1, \dots, Z_D$:

$$\phi(x) = \frac{1}{\sqrt{D}} (Z_1(x), \dots, Z_D(x)) \in \mathbb{R}^D,$$

de sorte que $\langle \phi(x), \phi(y) \rangle \approx K(x, y)$, avec une garantie de convergence uniforme sur le domaine compact $\Omega \subseteq B_1(0, R)$:

$$\mathbb{P} \left(\sup_{x, y \in \Omega} |\langle \phi(x), \phi(y) \rangle - K(x, y)| > \varepsilon \right) \leq 2 \left(\frac{32RL}{\varepsilon} \right)^{2d} \exp \left(-\frac{D\varepsilon^2}{8C_\Omega^2} \right),$$

où $C_\Omega = p f(pR^2)$ est une constante dépendant uniquement du domaine Ω , et $L = f'(R^2) + p^2 R \sqrt{d} f'(pR^2)$ est la constante de Lipschitz de l'erreur. En particulier, il suffit de prendre

$$D = \Omega \left(\frac{d C_\Omega^2}{\varepsilon^2} \log \frac{RL}{\delta} \right)$$

pour garantir l'approximation uniforme avec probabilité au moins $1 - \delta$.

2 Méthodes déterministes

2.1 Approximation par Quadrature Gaussienne

Dao, De Sa & Ré, “Gaussian Quadrature for Kernel Features”, *NeurIPS 2018*

Le taux de convergence de la méthode de Monte Carlo est en $O(D^{-\frac{1}{2}})$, où D est le nombre de features. Cela est considérablement lent et motive l'introduction d'une méthode déterministe par quadrature numérique pour approcher le kernel gaussien.

L'idée est de trouver des points $\omega_1, \dots, \omega_L$ et des poids $a_1, \dots, a_L$ tels que :

$$\int_{\mathbb{R}} f(\omega) \Lambda(\omega) d\omega \approx \sum_{i=1}^L a_i f(\omega_i)$$

Avec L points, cette règle est exacte pour tous les polynômes de degré inférieur ou égal à $2L - 1$. Lorsque Λ est la densité de la loi normale standard $\mathcal{N}(0, 1)$, les points $\omega_1, \dots, \omega_L$ sont les racines du polynôme de Hermite H_L de degré L . Les poids $a_1, \dots, a_L$ sont ensuite déterminés en résolvant le système linéaire :

$$\sum_{i=1}^L a_i \omega_i^k = \mathbb{E}_\Lambda[\omega^k], \quad k = 0, 1, \dots, L - 1$$

Le kernel gaussien admet la représentation spectrale suivante. Pour $u = x - y \in \mathbb{R}^d$:

$$k(u) = \exp\left(-\frac{\|u\|^2}{2}\right) = \int_{\mathbb{R}^d} e^{j\omega^\top u} \Lambda(\omega) d\omega$$

où $\Lambda(\omega) = \frac{1}{(2\pi)^{d/2}} e^{-\|\omega\|^2/2}$ est la densité spectrale associée au kernel gaussien.

Puisque $\Lambda(\omega) = \prod_{i=1}^d \Lambda_i(\omega_i)$ avec $\Lambda_i = \mathcal{N}(0, 1)$ et que $e^{j\omega^\top u} = \prod_{i=1}^d e^{j\omega_i u_i}$, l'intégrale se factorise en d intégrales 1D indépendantes :

$$k(u) = \prod_{i=1}^d \int_{\mathbb{R}} \Lambda_i(\omega_i) e^{j\omega_i u_i} d\omega_i$$

Dense grid. Chaque intégrale 1D $k_i(u_i)$ peut être approchée par une règle de quadrature de Gauss à L points. En notant :

$$G_i^L(u_i) := \sum_{\ell=1}^L \hat{a}_\ell^{(L)} e^{j\hat{\gamma}_\ell^{(L)} u_i}$$

où $\hat{\gamma}_1^{(L)}, \dots, \hat{\gamma}_L^{(L)}$ sont les racines de H_L et $\hat{a}_1^{(L)}, \dots, \hat{a}_L^{(L)}$ les poids correspondants, on obtient l'approximation par *dense grid* :

$$\tilde{k}(u) = \prod_{i=1}^d G_i^L(u_i) = \sum_{\ell \in \{1, \dots, L\}^d} a_\ell e^{j\omega_\ell^\top u}$$

où $\omega_\ell = (\hat{\gamma}_{\ell_1}^{(L)}, \dots, \hat{\gamma}_{\ell_d}^{(L)}) \in \mathbb{R}^d$ et $a_\ell = \prod_{i=1}^d \hat{a}_{\ell_i}^{(L)}$.

Cette approximation est néanmoins problématique en grande dimension : le nombre de points nécessaires est L^d .

Sparse grid. Pour remédier à ce problème, on introduit la *sparse grid* de Smolyak. L'idée est de décomposer chaque approximation 1D en une somme télescopique d'incrément, puis de ne conserver en dimension d que les combinaisons dont le niveau total est faible.

On définit les incréments 1D :

$$\Delta_{i,0}(u_i) := G_i^1(u_i)$$

$$\Delta_{i,m}(u_i) := G_i^{2^m}(u_i) - G_i^{2^{m-1}}(u_i) \quad \text{pour } m \geq 1$$

Ces incréments mesurent le gain de précision apporté en doublant le nombre de points. Puisque la quadrature de Gauss converge, la somme télescopique est exacte:

$$k_i(u_i) = \sum_{m=0}^{\infty} \Delta_{i,m}(u_i)$$

Les incréments $|\Delta_{i,m}(u_i)|$ décroissent rapidement avec m : les corrections de haut niveau sont négligeables.

En dimension d , le kernel s'écrit :

$$k(u) = \prod_{i=1}^d \sum_{m_i=0}^{\infty} \Delta_{i,m_i}(u_i) = \sum_{m \in \mathbb{N}^d} \underbrace{\prod_{i=1}^d \Delta_{i,m_i}(u_i)}_{\Delta_m(u)}$$

où $m = (m_1, \dots, m_d) \in \mathbb{N}^d$ est un vecteur de niveaux. Le coût de calcul de $\Delta_m(u)$ est proportionnel à $2^{\|m\|_1}$ où $\|m\|_1 = \sum_i m_i$ est le *niveau total*. Les termes de haut niveau total sont donc à la fois coûteux et peu importants.

La *sparse grid de niveau A* ne conserve que les termes de niveau total inférieur ou égal à A :

$$\tilde{k}(u) = \sum_{\substack{m \in \mathbb{N}^d \\ \|m\|_1 \leq A}} \Delta_m(u)$$

Le nombre de points nécessaires est $D \leq 3^A \binom{d+A}{A}$, polynomial en d pour A fixé, contre L^d pour le dense grid.

Erreur d'approximation. Pour un kernel à spectre b -sous-gaussien, l'erreur de la sparse grid de niveau A est bornée (Theorem 3 de l'article) par :

$$\sup_{\|u\| \leq M} |k(u) - \tilde{k}(u)| \leq 2^d \left(\frac{12eb^2 M^2}{A} \right)^A$$

Pour $A > 12eb^2 M^2$, cette borne décroît *exponentiellement* en A , contre $O(D^{-1/2})$ pour RFF.

2.2 Approximation de Nyström

Let the standard self-attention be defined as:

$$\text{Att}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d}}\right) V \quad (5)$$

Define the attention matrix:

$$S = \text{softmax}\left(\frac{QK^\top}{\sqrt{d}}\right) \in \mathbb{R}^{n \times n} \quad (6)$$

Nyströmformer approximates S using the Nyström method. Select m landmark points with $m \ll n$. Define $\tilde{Q}, \tilde{K} \in \mathbb{R}^{m \times d}$ constructed via segment-wise averaging:

$$\tilde{Q}_i = \frac{1}{|S_i|} \sum_{j \in S_i} Q_j \quad \tilde{K}_i = \frac{1}{|S_i|} \sum_{j \in S_i} K_j \quad (7)$$

where S_i denotes the i -th segment of tokens.

Define the following matrices:

$$A = \text{softmax}\left(\frac{Q\tilde{K}^\top}{\sqrt{d}}\right) \in \mathbb{R}^{n \times m} \quad (8)$$

$$B = \text{softmax}\left(\frac{\tilde{Q}\tilde{K}^\top}{\sqrt{d}}\right) \in \mathbb{R}^{m \times m} \quad (9)$$

$$C = \text{softmax}\left(\frac{\tilde{Q}K^\top}{\sqrt{d}}\right) \in \mathbb{R}^{m \times n} \quad (10)$$

Using the Nyström approximation:

$$S \approx AB^\dagger C \quad (11)$$

where $B^\dagger$ denotes the Moore–Penrose pseudoinverse of B .

Thus the approximated attention output becomes:

$$\hat{Y} = AB^\dagger CV \quad (12)$$