



École nationale des ponts et chaussées

Projet de département IMI 2025-2026

Antoine CHOSSON, Clara LIMA-GOLDENBERG, Youssef SAHRAOUI, Yassine KOUAS

Sous la direction de : Julien REYGNER, Adrien TOUBOUL

Entreprise : Advansight

RÉDUCTION DU COÛT DE CALCUL ET DE MÉMOIRE POUR LES LLMs LOCAUX

Approche Kernelisée du calcul d'attention

ABSTRACT

Le déploiement massif des modèles de langage de grande taille (LLMs) s'accompagne aujourd'hui d'un coût énergétique et financier considérable. Cette problématique découle en grande partie du mécanisme d'attention softmax dont la complexité quadratique en fonction de la longueur des séquences constitue un frein majeur au développement d'applications à long contexte. Dans ce projet, nous explorons une alternative fondée sur une approximation kernélisée de l'attention : FAVOR+ (*Fast Attention Via Positive Orthogonal Random Features*). Cette méthode repose sur une approximation linéaire du noyau exponentiel au moyen de projections sur des features aléatoires orthogonales positives. Notre démarche s'inscrit à la croisée de l'analyse théorique et de l'expérimentation appliquée. D'une part, nous étudions les propriétés spectrales du noyau exponentiel ainsi que celles de ses approximations à travers le cadre de la théorie des opérateurs intégraux. D'autre part, nous intégrons des têtes d'attention FAVOR+ au sein du modèle TinyLlama, en mobilisant une stratégie de distillation progressive des connaissances, afin d'évaluer l'impact de cette architecture sur la qualité de génération ainsi que sur l'organisation interne des représentations du modèle.

REMERCIEMENTS

Nous souhaitons adresser nos sincères remerciements à Adrien Touboul, de l'entreprise Advansight, ainsi qu'à Julien Reygner, chercheur et professeur à l'École des Ponts et Chaussées, pour la qualité de leur accompagnement, la pertinence de leurs conseils et la confiance qu'ils nous ont accordée tout au long de ce projet de recherche.

Table des matières

Introduction	4
1 État de l’art : Réduction des coûts de calcul par linéarisation	5
1.1 Le noyau et les théorèmes de décomposition	5
1.1.1 Lien entre noyaux et mécanisme d’attention	5
1.1.2 Noyaux et théorèmes de décomposition	5
1.2 Méthodes d’approximation du noyau exponentiel	6
1.2.1 Approximation de Nyström	6
1.2.2 Random Maclaurin Features (noyaux produit scalaire).	6
1.2.3 Spectraformer comme cadre unificateur des approximations par caractéristiques aléatoires	7
2 L’architecture Performer	8
2.1 Théorie du Performer	8
2.2 Implémentation en Python et substitution de l’attention standard dans un modèle open source	8
2.3 Mise en évidence des gains de complexité et de vitesse à l’échelle d’une tête d’attention	9
3 Évaluation théorique et expérimentale de l’architecture Performer FAVOR+	10
3.1 Théorie spectrale	10
3.1.1 Notations et hypothèses	10
3.1.2 Lien entre valeurs propres et erreur d’approximation	11
3.1.3 Calcul des valeurs propres d’un noyau	12
3.1.4 Limites de l’approche spectrale	13
3.2 Analyse des résultats : évaluation du modèle à attention classique contre ses variantes Performer	13
3.2.1 Approche bas niveau : comparaison des distributions	13
3.2.2 Approche haut niveau : comparaison des modèles en situation	14
3.2.3 Approche spectrale : étude des valeurs propres du noyau exponentiel et de son approximation	15
Conclusion	17
Annexes	18
Références	27

INTRODUCTION

Motivations

Le déploiement massif des modèles de langage de grande taille s'accompagne d'un coût énergétique croissant : l'inférence d'un LLM conversationnel peut consommer jusqu'à dix fois plus d'énergie qu'une requête web classique [10], pour des plateformes comptant désormais plusieurs centaines de millions d'utilisateurs actifs [14]. Cette problématique provient principalement du mécanisme d'attention softmax, dont la complexité quadratique $\mathcal{O}(n^2)$ limite fortement le passage à des contextes longs.

Plusieurs travaux récents cherchent à linéariser ce calcul via des approximations kernélisées de l'attention. Cette approche soulève toutefois une question centrale : dans quelle mesure ces approximations préservent-elles la structure fonctionnelle

et spectrale du noyau exponentiel original ? Nous abordons cette problématique à travers le cadre de la théorie des opérateurs intégraux et l'étude empirique des spectres des noyaux de Gram associés.

Sur le plan applicatif, nous étudions FAVOR+ [3], qui réduit la complexité à $\mathcal{O}(n)$ grâce à des projections aléatoires orthogonales positives. Son intégration dans un LLM pré-entraîné nécessite une stratégie de distillation permettant d'adapter progressivement le modèle à cette nouvelle architecture.

Ce travail vise ainsi à déterminer dans quelle mesure des têtes d'attention softmax peuvent être remplacées par des têtes FAVOR+ au sein d'un LLM pré-entraîné, tout en préservant la qualité de génération.

L'architecture Transformer pour les LLMs Conversationnels

Les modèles de grand langage modernes reposent majoritairement sur l'architecture Transformer introduite par Vaswani et al. [16].

Soit une séquence de tokens représentée par une matrice $X \in \mathbb{R}^{N \times d}$, où N désigne la longueur du contexte et d la dimension des représentations. Chaque couche d'attention projette les représentations d'entrée selon trois espaces distincts :

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

où Q , K et V correspondent respectivement aux matrices de *queries*, *keys* et *values*.

L'attention softmax s'écrit alors :

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} \right) V$$

Le produit $QK^\top \in \mathbb{R}^{N \times N}$ calcule les similarités entre tous les couples de tokens de la séquence. Cette étape constitue le principal coût computa-

tionnel du Transformer : la mémoire et le temps de calcul croissent quadratiquement avec la longueur de contexte, soit une complexité $\mathcal{O}(N^2)$.

Les LLMs empilent plusieurs dizaines de couches Transformer, chacune composée d'un bloc d'attention multi-têtes. Cette architecture permet au modèle de construire progressivement des représentations contextuelles riches, mais rend le passage à des contextes longs particulièrement coûteux en calcul et en mémoire.

Dans le cadre des LLMs conversationnels auto-régressifs, l'attention est rendue causale : chaque token ne peut porter son attention que sur les tokens précédents de la séquence, et jamais sur les tokens futurs. Cette contrainte est imposée par un masque triangulaire appliqué avant le softmax, garantissant que la génération respecte l'ordre temporel du texte. Lors de l'inférence, le modèle génère ainsi la réponse token par token, chaque prédiction étant conditionnée sur l'ensemble du contexte déjà produit.

État de l'art : Réduction des coûts de calcul par linéarisation

1.1 Le noyau et les théorèmes de décomposition

1.1.1 Lien entre noyaux et mécanisme d'attention

Le mécanisme d'attention constitue le cœur de l'architecture Transformer. Les méthodes de linéarisation reposent sur sa reformulation sous forme de noyau.

Soit x_i le vecteur représentant le i -ème token d'une séquence, $\mathbf{x} = [x_1, \dots, x_T]$ la séquence et $S_{\mathbf{x}} = \{x_1, \dots, x_T\}$ l'ensemble de ses éléments.

La couche d'attention peut se réécrire sous la forme d'un **lissage par noyau** [15] :

$$\text{Attention}(x_q, M(x_q, S_{x_k})) = \sum_{x_k \in M(x_q, S_{x_k})} \frac{k(x_q, x_k)}{\sum_{x'_k \in M(x_q, S_{x_k})} k(x_q, x'_k)} v(x_k)$$

où le noyau et la fonction de valeur sont définis par :

$$k(x_q, x_k) = \exp\left(\frac{\langle x_q W_q, x_k W_k \rangle}{\sqrt{d_k}}\right), \quad v(x_k) = x_k W_v.$$

1.1.2 Noyaux et théorèmes de décomposition

Un noyau est une fonction $k : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$. Il possède ainsi une forme très générale. On s'intéresse dans ce rapport aux noyaux symétriques définis positifs. Un noyau $k : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ est dit **symétrique** si : $\forall x, y \in \mathbb{R}^d, \quad k(x, y) = k(y, x)$.

Il est dit **défini positif** si pour tout $n \geq 1$, tout $x_1, \dots, x_n \in \mathbb{R}^d$ et tout $c_1, \dots, c_n \in \mathbb{R}$:

$$\sum_{i=1}^n \sum_{j=1}^n c_i c_j k(x_i, x_j) \geq 0.$$

Deux théorèmes permettent de décomposer un noyau en produit scalaire, ouvrant la voie à des approximations par features maps explicites. Le théorème de Bochner fonde directement les méthodes d'approximation par *random Fourier features* (Rahimi & Recht [13]) : il fournit une représentation explicite du noyau comme espérance, que l'on approche par Monte-Carlo. Le premier théorème, plus général, justifie quant à lui la vision RKHS et les méthodes de type Nyström. Ces deux approches seront détaillées dans la section suivante.

Théorème 1.1: Décomposition par feature map

Soit $k : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ un noyau symétrique défini positif. Il existe un espace de Hilbert $\mathcal{H}$ et une application $\phi : \mathbb{R}^d \rightarrow \mathcal{H}$ tels que :

$$\forall x, y \in \mathbb{R}^d, \quad k(x, y) = \langle \phi(x), \phi(y) \rangle_{\mathcal{H}}.$$

Théorème 1.2: Théorème de Bochner

Un noyau continu $k(x, y) = \kappa(x - y)$ invariant par translation est défini positif si et seulement si κ est la transformée de Fourier d'une mesure de probabilité $p(\omega) \geq 0$ sur $\mathbb{R}^d$:

$$\kappa(\delta) = \int_{\mathbb{R}^d} e^{i\omega^\top \delta} p(\omega) d\omega = \mathbb{E}_{\omega \sim p} [e^{i\omega^\top \delta}].$$

Dans le cas du noyau gaussien $k(x, y) = e^{-\|x-y\|^2/2}$, la mesure spectrale est $p = \mathcal{N}(0, I_d)$.

1.2 Méthodes d'approximation du noyau exponentiel

Nous nous intéressons à différentes approximations du noyau exponentiel, susceptibles de remplacer le mécanisme d'attention actuel.

1.2.1 Approximation de Nyström

L'approximation de Nyström applique une réduction du rang de la matrice d'attention. Contrairement aux méthodes basées sur des features aléatoires, elle cherche à approximer directement la matrice softmax par une décomposition de faible rang construite à partir d'un sous-ensemble représentatif de colonnes.

Dans [17], les auteurs proposent *Nyströmformer*, une approximation de l'attention fondée sur un ensemble de $m \ll N$ points de repère (*landmarks*) obtenus par regroupement des tokens de la séquence. L'attention complète est alors approchée par $A \approx F\tilde{A}^+B$, avec :

- F l'attention entre les requêtes et les landmarks,
- B l'attention entre les landmarks et les clés,
- $\tilde{A}^+$ la pseudo-inverse de la matrice d'attention entre landmarks.

Cette factorisation évite la construction explicite de la matrice d'attention complète de taille $N \times N$ et la complexité mémoire et temporelle passe de $\mathcal{O}(N^2)$ à $\mathcal{O}(Nm)$.

L'intérêt principal de l'approche Nyström réside dans sa capacité à conserver une approximation globale de la structure de l'attention via une représentation de faible rang.

1.2.2 Random Maclaurin Features (noyaux produit scalaire).

Pour les noyaux de la forme $K(x, y) = f(\langle x, y \rangle)$, comme le noyau exponentiel, le théorème de Bochner ne s'applique pas. [6] exploite à la place le fait que f est analytique à coefficients de Maclaurin non négatifs :

$$f(x) = \sum_{n=0}^{\infty} a_n x^n, \quad a_n \geq 0.$$

Les coefficients (a_n) définissent une mesure positive sur $\mathbb{N}$, ce qui permet d'estimer $K(x, y) = \sum_n a_n \langle x, y \rangle^n$ par Monte-Carlo. En tirant N selon une loi à queue exponentielle et des vecteurs de Rademacher $\omega_1, \dots, \omega_N \in \{-1, +1\}^d$, on construit l'estimateur non biaisé :

$$Z(x) = \sqrt{a_N p^{N+1}} \prod_{j=1}^N \omega_j^\top x, \quad \mathbb{E}[Z(x)Z(y)] = K(x, y).$$

L'approximation finale avec D copies indépendantes $\phi(x) = \frac{1}{\sqrt{D}}(Z_1(x), \dots, Z_D(x))$ requiert $D = \Omega\left(\frac{d}{\varepsilon^2} \log \frac{1}{\delta}\right)$ features pour une approximation uniforme à précision ε avec probabilité $1 - \delta$, avec une dépendance linéaire en d .

1.2.3 Spectraformer comme cadre unificateur des approximations par caractéristiques aléatoires

Les méthodes aléatoires se placent dans un cadre plus général fourni par Spectraformer [11]. L'intérêt de ce positionnement est de donner un formalisme commun aux approximations de l'attention par caractéristiques aléatoires.

Formalisme général. Soit $W \in \mathbb{R}^{m \times d}$ une matrice dont les lignes sont notées $w_1^\top, \dots, w_m^\top$. On considère une famille de fonctions $f_1, \dots, f_s : \mathbb{R} \rightarrow \mathbb{R}$, des poids $\gamma_1, \dots, \gamma_s \geq 0$, et une fonction d'enveloppe $h : \mathbb{R}^d \rightarrow \mathbb{R}$. Une application de caractéristiques compatible avec ce cadre peut s'écrire

$$\Phi_W(x) = \frac{h(x)}{\sqrt{m}} \left(\sqrt{\gamma_r} f_r(w_i^\top x) \right)_{\substack{1 \leq i \leq m \\ 1 \leq r \leq s}} \in \mathbb{R}^{ms}. \quad (1)$$

Le noyau approché est alors

$$\hat{k}_W(x, y) = \langle \Phi_W(x), \Phi_W(y) \rangle = \frac{h(x)h(y)}{m} \sum_{i=1}^m \sum_{r=1}^s \gamma_r f_r(w_i^\top x) f_r(w_i^\top y). \quad (2)$$

Si les lignes w_i sont échantillonnées selon une loi p et si le noyau cible admet la représentation

$$k(x, y) = h(x)h(y) \mathbb{E}_{w \sim p} \left[\sum_{r=1}^s \gamma_r f_r(w^\top x) f_r(w^\top y) \right], \quad (3)$$

$\hat{k}_W$ est un estimateur de Monte-Carlo de k . Il est non-biaisé si les lignes sont indépendantes et identiquement distribuées.

Lecture des méthodes existantes. Ce cadre fait apparaître les différences entre les familles d'approximation comme des choix de W , de f_r et de h . Les Random Fourier Features utilisent des fonctions trigonométriques et une loi spectrale associée à un noyau invariant par translation [13]. Les Random Maclaurin Features exploitent des fonctions polynomiales ou monomiales adaptées aux noyaux de produit scalaire [6]. Les Positive Random Features de Performer emploient des fonctions exponentielles positives afin d'approcher le noyau softmax. La matrice W peut être gaussienne indépendante, orthogonalisée comme dans les ORF, ou remplacée par des constructions structurées telles que FastFood [7] ou certaines règles de quadrature [4].

Attention linéarisée : Une fois le noyau remplacé par $\hat{k}_W(x, y) = \Phi_W(x)^\top \Phi_W(y)$, l'attention non causale peut s'écrire

$$\text{Att}(q_i, K, V) = \frac{\sum_{j=1}^N \Phi_W(q_i)^\top \Phi_W(k_j) v_j}{\sum_{j=1}^N \Phi_W(q_i)^\top \Phi_W(k_j)} = \frac{\Phi_W(q_i)^\top \left(\sum_{j=1}^N \Phi_W(k_j) v_j \right)}{\Phi_W(q_i)^\top \left(\sum_{j=1}^N \Phi_W(k_j) \right)}. \quad (4)$$

Le passage de la forme de gauche à la forme de droite est le mécanisme algébrique qui remplace le calcul explicite de la matrice d'attention par deux accumulateurs de taille proportionnelle au nombre de caractéristiques. En mode causal, ces sommes deviennent des préfixes cumulés, ce qui permet un décodage incrémental à état maintenu.

L'architecture Performer

2.1 Théorie du Performer

Dans le cadre Spectraformer introduit en section 1.2.3, FAVOR+ [3] correspond au choix suivant pour approcher le noyau softmax $\text{SM}(x, y) = \exp(x^\top y)$, où l'on pose $x = q/d^{1/4}$ et $y = k/d^{1/4}$:

- SM_m^{d+} : $h(x) = \exp(-\|x\|^2/2)$, $s = 1$, $f_1(u) = \exp(u)$
- $\text{SM}_m^{d\text{hyp}+}$: conçu pour réduire la variance, $h(x) = \frac{1}{\sqrt{2}} \exp(-\|x\|^2/2)$, $s = 2$, $f_1(u) = \exp(u)$, $f_2(u) = \exp(-u)$

Ces deux estimateurs sont non biaisés [3] : pour tout $x, y \in \mathbb{R}^d$,

$$\mathbb{E}[\langle \Phi_W(x), \Phi_W(y) \rangle] = \exp(x^\top y) = \text{SM}(x, y).$$

De plus, les $\omega_1, \dots, \omega_m$ sont choisis orthogonaux entre eux tout en respectant marginalement la distribution $\mathcal{N}(0, I_d)$ (*Orthogonal Random Features*, ORF). En forçant l'orthogonalité, on évite que deux vecteurs ω_i et ω_j portent une information redondante, ce qui réduit la variance de l'estimateur et améliore. La combinaison de ces deux choix, features positives et orthogonalité, constitue le mécanisme **FAVOR+** (*Fast Attention Via positive Orthogonal Random features*).

2.2 Implémentation en Python et substitution de l'attention standard dans un modèle open source

1

L'implémentation repose sur la librairie `PyTorch` et la bibliothèque `HuggingFace Transformers`. Le code est organisé en deux modules indépendants : `performer/` contient le noyau FAVOR+ (feature maps, scan causal, kernel Triton), tandis que `finetune/` regroupe la logique de substitution dans TinyLlama ainsi que les mécanismes de distillation. Cette séparation permet de réutiliser la classe `PerformerAttentionCore` dans n'importe quelle architecture sans modifier le code de fine-tuning. Le modèle TinyLlama1.1B a été retenu comme modèle *teacher* pour trois raisons principales :

1. Son architecture est un LLaMA à l'architecture standard ce qui facilite la substitution chirurgicale des couches d'attention.
2. Son faible nombre de paramètres permet un cycle complet entraînement/évaluation sur un unique GPU.
3. Ses 32 têtes d'attention offrent une granularité suffisante pour une modification progressive (4, 8, 16 puis 32 têtes remplacées).

Le module `PerformerAttentionCore` est codé sans projections Q/K/V qui sont natives à chaque *teacher model*. Il reçoit directement les tenseurs projetés et retourne la sortie d'attention. Ce découplage permet de l'insérer dans n'importe quelle architecture sans toucher aux poids existants.

1. Tous les fichiers relatifs à l'implémentation en code du performer sont disponibles sur le repo GitHub <https://github.com/Antoinechss/Performer-attention-LLM.git>
 Le modèle TinyLlama1.1B-Chat-v1.0 fine-tuned pour le performer est disponible sur le repo HuggingFace <https://huggingface.co/antoinechss/performer-checkpoints>

La substitution dans TinyLlama se fait en une passe sur les couches. Les k premières têtes sont routées vers FAVOR+, les $32 - k$ restantes conservent le softmax standard les deux flux se rejoignant dans la projection "out".

Scan causal et coût mémoire :

L'attention causale FAVOR+ repose sur une récurrence séquentielle : $S_i = S_{i-1} + \phi(k_i)v_i^\top$

Une implémentation naïve nécessiterait de stocker l'ensemble des états intermédiaires pour le backward, entraînant un coût mémoire en $O(N \cdot M \cdot D)$. Pour éviter cette explosion mémoire, l'implémentation utilise le **gradient checkpointing** : les états intermédiaires ne sont plus conservés et le forward est recalculé lors du backward. La mémoire est ainsi réduite à $O(M \cdot D)$ au prix d'un surcoût de calcul.

Des évaluations théoriques ont ensuite été réalisées afin de valider l'implémentation du modèle ainsi que sa convergence vers le softmax classique. Les résultats détaillés sont présentés en annexe ??.

La substitution directe sans réentraînement dégrade immédiatement la qualité : les projections Q/K/V ont été optimisées pour produire des distributions softmax, pas FAVOR+. Un **fine-tuning par distillation de connaissances** depuis le modèle softmax figé est donc nécessaire. La stratégie détaillée de finetuning est expliquée en annexe 3.2.3

2.3 Mise en évidence des gains de complexité et de vitesse à l'échelle d'une tête d'attention

Afin de vérifier le passage d'un calcul d'attention quadratique à linéaire, on confronte les durées d'inférence d'un modèle à attention classique versus sa version Performer. Cette comparaison est réalisée par inférence simultanée, sur le même GPU (Nvidia A100) afin de limiter les variables confondantes. L'inférence se divise en deux phases, étudiées séparément ici.

- **Prefill** : le modèle traite le prompt entier en une seule passe. Tous les tokens d'entrée sont traités en parallèle. C'est là que le coût $O(N^2)$ de l'attention est important. Plus le prompt est long plus l'inférence est lente.
 - **Decode** : le modèle génère sa réponse, token par token. À chaque étape, le modèle produit un seul nouveau token en s'appuyant sur tout ce qui précède. Cette phase est séquentielle par construction, sa complexité est dominée davantage par la bande passante mémoire que par le calcul. Les résultats suivent une tendance similaire et sont présentés en annexe ??.
- On retiendra simplement que la latence du Performer y est quasi-constante en N, contre une croissance linéaire pour le softmax à grand contexte.

M	M/D	M/N	Performer (ms)	Speedup vs Softmax
32	0.5	0.02	4.11	1.93
64	1.0	0.03	8.58	0.92
128	2.0	0.06	6.08	1.31
256	4.0	0.12	9.89	0.80
512	8.0	0.25	144.60	0.05
1024	16.0	0.50	650.66	0.01
2048	32.0	1.00	1286.72	0.01

TABLE 1 – Impact du nombre M de features aléatoires sur la rapidité du Performer à N=2048 fixé




FIGURE 1 – L’architecture Performer révèle son avantage calculatoire pour des longues séquences

Deux procédés sont adoptés dans les expériences ci-dessus. Figure 2 : On fixe la dimension M de l’approximation et on varie la longueur du contexte N . Table 1 : On fixe le contexte à $N = 2048$ tokens et on varie la qualité de l’approximation. Les deux tables convergent vers la même conclusion : le Performer n’a d’intérêt que si $M \ll N$ et le cas échéant se montre jusqu’à 3x plus rapide et au delà. Les résultats montrent que le performer perd son avantage lorsque la dimension d’approximation est moins de 10x inférieure à la dimension de départ. Passé ce seuil, l’overhead de l’implémentation, le sampling aléatoire des features et l’accumulation séquentielle de l’état du scan absorbent le gain théorique.

Cette étude conduit au choix du paramètre **$M=256$** , qui offre le meilleur compromis entre précision et coût computationnel. Avec $D = 64$, cette valeur permet d’obtenir une approximation très proche de l’attention softmax (similarité cosinus de 0.994) tout en conservant une latence et une consommation mémoire raisonnables. Augmenter davantage M apporte des gains limités pour un coût significativement plus élevé.

3

Évaluation théorique et expérimentale de l’architecture Performer FAVOR+

3.1 Théorie spectrale

Plusieurs travaux analysant les approximations du softmax (notamment dans les modèles de type Performers) mettent en évidence une perte de sens dans les prédictions. On parle d’une perte de capacité à distinguer le bruit contextuel des informations importantes ou d’effectuer des tâches type « needle in a haystack ». Nous essayons de comprendre ce phénomène avec une étude théorique et ensuite pratique des spectres des kernels que l’on étudie.

3.1.1 Notations et hypothèses

Soit μ une mesure de probabilité sur $\mathbb{R}^d$

Nous suivons les hypothèses faites dans [1] et on s'intéresse au spectre d'un noyau $k : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$. On suppose que k est défini positif et symétrique. De plus, on suppose que :

$$\int_{\mathbb{R}^d} k(x, x) d\mu(x) < +\infty$$

On définit l'opérateur intégral $T_k : L_2(\mu) \rightarrow L_2(\mu)$: pour tout $f \in L_2(\mu)$ et $x \in \mathbb{R}^d$,

$$T_k f(x) = \int_{\mathbb{R}^d} k(x, y) f(y) d\mu(y)$$

Le spectre de k est l'ensemble des valeurs propres $(\lambda_m)_{m \geq 0}$ de T_k , c'est-à-dire les réels tels qu'il existe $\phi_m \in L_2(\mu)$ non nul vérifiant :

$$T_k \phi_m = \lambda_m \phi_m$$

3.1.2 Lien entre valeurs propres et erreur d'approximation

Nous cherchons à établir une borne inférieure de l'erreur d'approximation du noyau k . L'idée vient de l'inégalité de Hoffman-Wielandt [2] en dimension finie :

$$\sum_{i=1}^n |\lambda_i - \mu_i|^2 \leq \|A - B\|_F^2 \quad (5)$$

où A et B sont deux matrices complexes normales, $\lambda_1, \dots, \lambda_n$ les valeurs propres de A et $\mu_1, \dots, \mu_n$ celles de B , triées dans l'ordre décroissant. $\|\cdot\|_F$ désigne la norme de Frobenius, définie par $\|M\|_F = \sqrt{\sum_{i,j} |m_{i,j}|^2}$.

Les définitions relatives à la théorie des opérateurs sur les espaces de Hilbert (adjoint, opérateur normal, compact, défini positif, Hilbert-Schmidt) sont données dans [8]. Une fois ces définitions établies, nous pouvons comprendre les hypothèses de l'inégalité généralisée [5] :

Théorème 3.1: Hoffmann-Wielandt pour les opérateurs de Hilbert-Schmidt

Soient A et B deux opérateurs de Hilbert-Schmidt normaux agissant sur un espace de Hilbert $\mathcal{H}$. Soient $\{\alpha_i\}_{i=1}^\infty$ et $\{\beta_i\}_{i=1}^\infty$ des énumérations de leurs valeurs propres respectives et soient $\{\alpha'_i\}_{i=1}^\infty$ et $\{\beta'_i\}_{i=1}^\infty$ des énumérations étendues (incluant la multiplicité de la valeur propre 0). Pour tout $\epsilon > 0$, il existe une permutation π de $\mathbb{N}$ telle que :

$$\left(\sum_{i=1}^\infty |\alpha_{\pi(i)} - \beta_i|^2 \right)^{1/2} \leq \|A - B\|_{HS} + \epsilon \quad (6)$$

De plus,

$$\left(\sum_{i=1}^\infty |\alpha_{\pi(i)'} - \beta'_i|^2 \right)^{1/2} \leq \|A - B\|_{HS} \quad (7)$$

Nous cherchons ainsi à appliquer les théorèmes précédents. Il faut ainsi vérifier que les opérateurs intégraux vérifient les hypothèses du théorème de Hoffmann-Wielandt pour les opérateurs de Hilbert-Schmidt. La preuve est en annexe.

Théorème 3.2: Opérateur linéaire continu

- T_k est un opérateur linéaire continu de $L_2(\mu)$ dans $L_2(\mu)$.
- T_k est auto-adjoint et donc normal
- T_k est compact
- T_k est un opérateur de Hilbert-Schmidt.

Nous pouvons ainsi appliquer le théorème aux noyaux exponentiel et ses approximations.

Néanmoins, l'inégalité concerne encore les opérateurs eux-mêmes. Pour aboutir, nous exprimons la norme de Hilbert-Schmidt de la différence d'opérateurs en fonction des noyaux eux-mêmes. Le calcul est détaillé en annexe 3.2.3. Nous avons que pour tout $\epsilon > 0$, d'après le théorème 3.1.2, il existe une permutation π de $\mathbb{N}$ telle que :

$$\left(\sum_{i=0}^{\infty} |\lambda_{\pi(i)} - \hat{\lambda}_i|^2 \right)^{1/2} \leq \|T_k - T_{\hat{k}}\|_{HS} + \epsilon = \left(\int_{\mathbb{R}^d \times \mathbb{R}^d} (k(x, y) - \hat{k}(x, y))^2 d\mu(x) d\mu(y) \right)^{1/2} + \epsilon \quad (8)$$

En considérant les énumérations étendues des valeurs propres, il existe une permutation π de $\mathbb{N}$ telle que :

$$\left(\sum_{i=0}^{\infty} |\lambda_{\pi(i)} - \hat{\lambda}_i|^2 \right)^{1/2} \leq \left(\int_{\mathbb{R}^d \times \mathbb{R}^d} (k(x, y) - \hat{k}(x, y))^2 d\mu(x) d\mu(y) \right)^{1/2} \quad (9)$$

Ainsi, minimiser l'erreur L^2 entre les noyaux k et $\hat{k}$ contrôle directement l'écart entre leurs spectres respectifs.

3.1.3 Calcul des valeurs propres d'un noyau

Une fois l'inégalité établie, il est important d'être capable de calculer les valeurs propres des noyaux étudiés.

Théorème 3.3: Approximation des valeurs propres par la matrice de noyau

Soit n observations $x_1, \dots, x_n$ i.i.d. suivant μ . La matrice de noyau $K \in \mathbb{R}^{n \times n}$ est définie par $K_{ij} = k(x_i, x_j)$. Les valeurs propres de $\frac{1}{n}K$ convergent vers les valeurs propres (λ_m) de T_k lorsque $n \rightarrow \infty$.

La preuve est détaillée dans [1]. Ce résultat permet d'estimer le spectre de T_k empiriquement à partir de données. Pour les noyaux admettant une décomposition en feature map explicite, on peut également calculer le spectre via la matrice de Gram.

Théorème 3.4: Spectre via la matrice de Gram

Soit $\phi_1, \dots, \phi_D : \mathbb{R}^d \rightarrow \mathbb{R}$ des fonctions linéairement indépendantes et $\hat{k}(x, y) = \sum_{j=1}^D \phi_j(x) \phi_j(y)$. On définit la matrice de Gram $G \in \mathbb{R}^{D \times D}$ par :

$$G_{ij} = \langle \phi_i, \phi_j \rangle_{L_2(\mu)} = \int \phi_i(x) \phi_j(x) d\mu(x).$$

Alors $T_{\hat{k}}$ et G ont les mêmes valeurs propres non nulles.

3.1.4 Limites de l'approche spectrale

Dans un Transformer réel, les matrices de requêtes et de clés sont distinctes — $Q = XW_Q$ et $K = XW_K$ avec $W_Q \neq W_K$ — donc la matrice d'attention $\widehat{K}_{QK} = \Phi(Q)\Phi(K)^\top$ n'est pas nécessairement symétrique. Le cadre théorique développé en section 3.1, qui repose sur des noyaux symétriques définis positifs et des opérateurs de Hilbert-Schmidt auto-adjoints, ne s'applique donc pas directement. Il constitue néanmoins une approche pour comprendre les approximations d'un point de vue fonctionnel : en étudiant comment les choix de W , des fonctions f_r , de la dimension m et de la normalisation h influencent la structure spectrale de l'opérateur intégral associé, on espère dégager des critères théoriques qui se traduisent en une meilleure qualité d'approximation en pratique.

3.2 Analyse des résultats : évaluation du modèle à attention classique contre ses variantes Performer

L'évaluation est conduite à trois niveaux complémentaires. Une première approche "bas niveau" des distributions de sortie du modèle sur l'ensemble des tokens. Une évaluation "haut niveau" de la qualité de génération sur des prompts ciblés. Une étude des propriétés spectrales des noyaux d'attention avant et après distillation. Les trois approches ainsi que leurs résultats sont présentées dans la section qui suit.

3.2.1 Approche bas niveau : comparaison des distributions

Cette première approche "bas niveau" compare les distributions sur les logits générées par chaque modèle. Pour chaque prompt 3.2.3, on tokenise, on effectue un forward pass complet avec le teacher et le student, et on compare les logits token par token.




FIGURE 2 – Divergence de Kullback-Leibler




FIGURE 3 – Top-1 agreement

Le modèle 4 têtes performer est très proche du modèle teacher avec une divergence KL (3.2.3) de 0.15. Sa valeur change très peu lors du passage à 8 et 16 têtes ; le signe que la distillation est efficace. Malgré une attention "deux fois plus linéaire", le modèle student perçoit les données presque de la même façon que le classique. La divergence KL explose à 2.84 pour le modèle à 32 têtes performer. Cette divergence est due à une distillation insuffisante. Lors du remplacement total, il n'y a plus aucune tête softmax pour absorber les patterns d'attention complexes que FAVOR+ ne sait pas reproduire.

Le top-1 agreement (3.2.3) montre que le modèle à 8 têtes obtient le meilleur accord avec le teacher en sortie. Ce résultat s'explique en partie par la stratégie de fine-tuning : le modèle à 4 têtes n'a été adapté qu'avec les projections Q et K dégelées, tandis que les modèles suivants ont bénéficié d'un

dégel plus large des projections Q/K/V/O. Au-delà de 16 têtes, l'accord diminue fortement, jusqu'à rendre le modèle à 32 têtes peu exploitable en pratique.

3.2.2 Approche haut niveau : comparaison des modèles en situation

La **perplexité** constitue une première mesure globale de la qualité du modèle : elle quantifie, en moyenne, à quel point le modèle est "surpris" par le token suivant dans un texte de référence. Une définition formelle de la perplexité est définie en annexe 3.2.3. La perplexité est estimée sur un ensemble de validation de phrases encyclopédiques courtes, distinct des prompts de génération qualitative.

Modèle	Têtes FAVOR+	Perplexité
Softmax	0/32	8.02
Phase 1	4/32	8.89
Phase 2	8/32	11.68
Phase 3	16/32	11.01
Phase 4	32/32	250.91

TABLE 2 – Perplexité des modèles selon la phase de distillation.

Les phases 1 et 2 maintiennent une perplexité satisfaisante avec respectivement +11% et +46% par rapport au modèle de référence. La phase 3 présente une perplexité légèrement meilleure que la phase 2, ce qui s'explique probablement par la variance des mesures plutôt qu'une amélioration réelle. La phase 4, avec toutes les têtes remplacées, s'effondre à 250.91 ; cohérent avec la divergence observée dans le tableau 2 .

Les scores Bilingual Evaluation Understudy (BLEU [12]) et Recall-Oriented Understudy for Gisting Evaluation (ROUGE [9]) sont deux métriques de référence en Machine Learning pour évaluer la qualité de génération d'un modèle de grand langage.

BLEU score : Évalue les capacités de traduction d'un modèle. Il mesure la précision des n-grammes du texte généré présents dans le texte de référence, pour n allant de 1 à 4. Un facteur de pénalité de brièveté (*brevity penalty*) est appliqué pour éviter que des textes très courts obtiennent artificiellement un score élevé. Le score final est la moyenne géométrique des précisions par ordre de n-gramme, multiplié par cette pénalité et varie entre 0 et 1.

ROUGE score : Évalue les capacités de summarisation d'un modèle par mesure de rappel. Il quantifie quelle fraction des n-grammes de la référence apparaît dans le texte généré. ROUGE-1 et ROUGE-2 opèrent respectivement sur les unigrammes et bigrammes, tandis que ROUGE-L capture la plus longue sous-séquence commune (*Longest Common Subsequence*), rendant la métrique plus sensible à l'ordre des mots. On utilise ici ROUGE-L car il capture à la fois le recouvrement lexical et la cohérence locale de la séquence.

Configuration	BLEU-1	ROUGE-L
Phase 1 – 4/32	0.244	0.235
Phase 2 – 8/32	0.231	0.256
Phase 3 – 16/32	0.335	0.316
Phase 4 – 32/32	0.001	0.092

TABLE 3 – Scores BLEU et ROUGE moyens par phase

Les scores des phases 1 et 2 montrent que les générations restent dans le même registre sémantique que la référence et émettent des réponses cohérentes sur des sujets génériques (histoire de l'IA, définition des nombres premiers etc.), avec une divergence lexicale contenue. La phase 3 affiche

paradoxalement les meilleurs scores sur toutes les métriques. Ce résultat provient des boucles de répétition observées qualitativement lors de la génération (« *A prime number is a positive integer that is greater than 1* » répété dix fois) maximisent artificiellement le rappel. La phase 4 s’effondre complètement, cohérent avec la perplexité de 250.91 : le remplacement intégral des 32 têtes d’attention par FAVOR+ sans budget d’entraînement suffisant détruit la capacité générative du modèle.

Évaluation qualitative des sorties générées sur trois prompts couvrant les registres : histoire de l’IA, mathématiques (définition d’un nombre premier) et géographie (informations sur la Tour Eiffel). Le tableau ci-dessous délivre des appréciations qualitatives sur les générations. Les réponses de chaque modèle sont en annexe 3.2.3.

Phase	Appréciation générale	IA	Mathématiques	Géographie
1	Générations très proches du teacher	Référence correcte à IBM Watson comme IA médicale	Définition légèrement imprécise mais fluide et grammaticalement correcte	Bonne cohérence sémantique et affirmations correctes
2	Premières dégradations malgré une génération globalement fluide	Texte tronqué mais références pertinentes (AlphaGo, IBM Watson)	Mention de propriétés correctes sans définition rigoureuse	Affirmations globalement correctes ; apparition de répétitions
3	Dérive thématique marquée et boucles de répétition	Texte cohérent mais hors sujet (imprimerie du XV ^e siècle)	Répétitions de définitions fausses ou incomplètes	Structure grammaticale préservée mais contenu erroné
4	Effondrement complet des générations	Fragments incohérents et répétitions	Fragments incohérents et répétitions	Fragments incohérents et répétitions

TABLE 4 – Évaluation qualitative des générations selon le nombre de têtes FAVOR+ intégrées.

3.2.3 Approche spectrale : étude des valeurs propres du noyau exponentiel et de son approximation

Le spectre d’un noyau (l’ensemble de ses valeurs propres) caractérise la richesse des interactions qu’il peut représenter. Comparer Le spectre du noyau exponentiel sous-jacent à l’attention softmax à celui de son approximation FAVOR+ permet ainsi de quantifier, au sens fonctionnel, ce que l’approximation par features aléatoires fait perdre structurellement. Pour formaliser cette comparaison, on s’appuie sur la théorie des opérateurs intégraux.

Pour comprendre le comportement numérique des approximations, nous observons les valeurs propres du noyau exponentiel et des différentes approximations sur des données aléatoires. Nous considérons $X \sim \mathcal{N}\left(0, \frac{1}{3d}I_d\right)$ et $\omega \sim \mathcal{N}(0, I_d)$, avec $D = 1000$, $n = 200$, et $d \in \{10, 50, 100, 500\}$.




FIGURE 4 – Valeurs propres des différentes approximations et du noyau exponentiel

Dans la Figure 4, on observe que pour toutes les valeurs de d , les quatre courbes de valeurs propres suivent les mêmes variations qualitatives : ceci confirme que les approximations capturent bien la structure spectrale du noyau exponentiel. On observe cependant qu’à D fixé, l’écart entre le noyau exact et les approximations se creuse à mesure que d augmente, traduisant une dégradation de la qualité d’approximation en grande dimension.

Nous cherchons à vérifier la théorie et les résultats obtenus avec les données jouet. Pour ce faire, on extrait durant la phase d’inférence les matrices kernel empiriques pour les deux noyaux. En capturant les hidden states $x_1, \dots, x_n$ en entrée de chaque couche et en les projetant via les poids W_Q et W_K du modèle, on construit les matrices $K \in \mathbb{R}^{n \times n}$ avec $K_{ij} = k(x_i, x_j)$, pour le noyau exponentiel sous-jacent à l’attention softmax $k(x_i, x_j) = \exp\left(\frac{q_i \cdot k_j}{\sqrt{d}}\right)$ et $k(x_i, x_j) = \phi(q_i) \cdot \phi(k_j)$ pour FAVOR+. Les matrices sont symétrisées puis normalisées par n , et le module `eigvalsh` calcule les valeurs propres réelles de $\frac{1}{n}K$, moyennées sur 5 prompts. L’analyse est conduite sur les couches 0, 5, 10, 15, 21 de TinyLlama, pour le modèle softmax de référence, le modèle FAVOR+ sans finetuning, et les quatre phases de distillation.




FIGURE 5 – Valeurs propres des différents noyaux au travers des couches du modèle

Les spectres empiriques montrent une différence structurelle entre les deux noyaux. Le spectre du noyau exponentiel sous-jacent à l’attention softmax est riche et décroît lentement : à la couche 15, on observe une cinquantaine de valeurs propres significatives. Le spectre du FAVOR+ s’effondre quasi-systématiquement en rang 1 et toutes les valeurs propres suivantes tombent à 10^{-18} . La forme factorisée du noyau $k(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$ produit une matrice de rang au plus M . On observe néanmoins qu’un seul mode concentre la quasi-totalité de l’énergie.

Les résultats empiriques montrent une limite de l’approche spectrale. C’est un levier pour l’améliorer l’approche d’un point de vue fonctionnel. Nous observons en effet des comportements similaires entre les différents mécanismes d’attention. Cependant, cette similarité spectrale n’est pas suffisante pour garantir que l’approximation fonctionnera après la distillation. L’inégalité de Hoffmann-Wielandt assure que l’écart entre les spectres de $T_{k_{\text{softmax}}}$ et $T_{k_{\text{FAVOR+}}}$ borne inférieurement la distance entre les deux opérateurs ; distance que la distillation ne peut réduire, car elle agit sur les poids W_Q, W_K, W_V, W_O et non sur la forme fonctionnelle du noyau.

CONCLUSION

Ce travail a permis d'étudier les approches de linéarisation de l'attention sous un double angle théorique et expérimental. D'un point de vue théorique, l'analyse des noyaux d'attention à travers le cadre des opérateurs intégraux met en évidence une différence structurelle importante entre le noyau exponentiel associé au softmax et son approximation FAVOR+. L'étude spectrale montre notamment que la richesse fonctionnelle du noyau softmax n'est pas entièrement préservée par les approximations de type random features, même après distillation.

Sur le plan pratique, l'intégration progressive de têtes FAVOR+ au sein de TinyLlama montre qu'une substitution partielle reste néanmoins viable. Les expériences confirment les gains attendus en complexité et en vitesse d'inférence pour les contextes longs, avec des accélérations supérieures à $\times 3$ dans certains régimes. Les évaluations qualitatives et quantitatives montrent cependant qu'un remplacement complet des têtes d'attention dégrade fortement la stabilité et la qualité des générations.

La phase 2 de distillation (8 têtes FAVOR+ sur 32) apparaît ainsi comme le meilleur compromis entre accélération et préservation des capacités génératives du modèle. Elle conserve des performances linguistiques et contextuelles globalement cohérentes tout en bénéficiant des gains apportés par la linéarisation de l'attention.

Ces résultats suggèrent que les approches de type Performer constituent une piste crédible pour réduire le coût des LLMs locaux en adoptant une architecture hybride conservant une part d'attention softmax exacte permettant de préserver une part de la structure spectrale du noyau original.

Preuves de la partie spectrale

Théorème .5: Caractérisation par les suites :

Soit $T \in \mathcal{L}(\mathcal{H})$. L'opérateur T est compact si et seulement si pour toute suite $(u_n)_{n \geq 0}$ qui converge faiblement vers u dans $\mathcal{H}$, $(Tu_n)_{n \geq 0}$ converge fortement convergente vers Tu .

Théorème .6: Théorème Spectral pour les opérateurs compacts

Soit V un espace de Hilbert de dimension infinie, et A un opérateur linéaire, continu, défini positif, auto-adjoint et compact de V dans V . Alors :

1. Les valeurs propres de A forment une suite $(\lambda_k)_{k \geq 1}$ de réels strictement positifs, décroissante et tendant vers 0 : $\lim_{k \rightarrow \infty} \lambda_k = 0$.
2. Il existe une base hilbertienne $(u_k)_{k \geq 1}$ de V formée de vecteurs propres de A , telle que :

$$\forall k \geq 1, \quad Au_k = \lambda_k u_k$$

3. Pour chaque valeur propre λ_k , le sous-espace propre associé est de dimension finie.

Théorème .7: Opérateur Linéaire Continu

Soit $k : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ défini positif et symétrique tel que :

$$\int_{\mathbb{R}^d} k(x, x) d\mu(y) < +\infty$$

Alors, T_k est un opérateur linéaire continu de $L_2(\mu)$ dans $L_2(\mu)$.

Preuve :

Il est clair que T_k est linéaire. Montrons dans un premier temps que T_k est bien défini.

Il existe H un espace de hilbert et $\phi : \mathbb{R}^d \rightarrow H$ tel que pour tout $(x, y) \in \mathbb{R}^d$,

$$k(x, y) = \langle \phi(x), \phi(y) \rangle$$

.

Let $f \in L_2(\mu)$ and $x \in \mathbb{R}^d$ be. On a :

$$|T_k f(x)| = \left| \int_{\mathbb{R}^d} k(x, y) f(y) d\mu(y) \right| \leq \int_{\mathbb{R}^d} |\langle \phi(x), \phi(y) \rangle f(y)| d\mu(y)$$

Par Cauchy-Schwartz :

$$|T_k f(x)| \leq \int_{\mathbb{R}^d} \|\phi(x)\| \|\phi(y)\| |f(y)| d\mu(y) = \|\phi(x)\| \int_{\mathbb{R}^d} \|\phi(y)\| |f(y)| d\mu(y) \quad (10)$$

Donc :

$$\int_{\mathbb{R}^d} |T_k f(x)|^2 d\mu(x) \leq \int_{\mathbb{R}^d} \|\phi(x)\|^2 \left(\int_{\mathbb{R}^d} \|\phi(y)\| |f(y)| d\mu(y) \right)^2 d\mu(x)$$

Or, $\|\phi(x)\|^2 = k(x, x)$. Par Cauchy-Schwartz :

$$\int_{\mathbb{R}^d} |T_k f(x)|^2 d\mu(x) \leq \int_{\mathbb{R}^d} k(x, x) d\mu(x) \int_{\mathbb{R}^d} k(y, y) d\mu(y) \int_{\mathbb{R}^d} |f(y)|^2 d\mu(y) \quad (11)$$

Nous avons ainsi :

$$\|T_k f\|_{L_2(\mu)} \leq C \|f\|_{L_2(\mu)}$$

T_k est bien défini et d'après l'inégalité établie, comme il est linéaire, il est continu.

Théorème .8: Un Auto Adjoint est normal

T_k est auto-adjoint et donc normal

Preuve :

Soit $f, g \in L_2(\mu)$.

Par définition :

$$\langle T_k f, g \rangle_{L_2(\mu)} = \int_{\mathbb{R}^d} T_k f(x) g(x) d\mu(x) = \int_{\mathbb{R}^d} \left(\int_{\mathbb{R}^d} k(x, y) f(y) d\mu(y) \right) g(x) d\mu(x)$$

On conclut avec Fubini que :

$$\langle T_k f, g \rangle_{L_2(\mu)} = \langle f, T_k g \rangle_{L_2(\mu)}$$

Théorème .9: Compacité

T_k est compact

Preuve :

Soit $(u_n)_{n \geq 0}$ une suite de $L_2(\mu)$ faiblement convergente vers $u \in L_2(\mu)$.

Soit $x \in \mathbb{R}^d$. On pose $g_x : y \in \mathbb{R}^d \rightarrow k(x, y)$. D'après la preuve du théorème 3.2.3 :

$$\int_{\mathbb{R}^d} g_x(y)^2 d\mu(y) \leq \|\phi(x)\| \int_{\mathbb{R}^d} \|\phi(y)\| d\mu(y) < +\infty$$

Donc, $g_x \in L_2(\mu)$ et par hypothèse :

$$\langle u_n, g_x \rangle_{L_2(\mu)} \rightarrow \langle u, g_x \rangle_{L_2(\mu)}$$

Or,

$$\langle u_n, g_x \rangle_{L_2(\mu)} = \int_{\mathbb{R}^d} k(x, y) u_n(y) d\mu(y) = T_k u_n(x) \text{ et } \langle u, g_x \rangle_{L_2(\mu)} = T_k u(x)$$

Donc, pour tout $x \in \mathbb{R}^d$, $T_k u_n(x) \rightarrow T_k u(x)$.

Montrons la convergence dans $L_2(\mu)$:

$$\|T_k u_n - T_k u\|_{L_2(\mu)}^2 = \int_{\mathbb{R}^d} (T_k u_n(y) - T_k u(y))^2 d\mu(y)$$

Notons pour tout $n \in \mathbb{N}$, $\psi_n : x \in \mathbb{R}^d \rightarrow (T_k u_n(y) - T_k u(y))^2$.

Pour tout $x \in \mathbb{R}^d$, $\psi_n(x) \rightarrow 0$.

De plus, soit $x \in \mathbb{R}^d$ et $n \in \mathbb{N}$, par linéarité de T_k et d'après l'inégalité 10

$$|\psi_n(x)| = (T_k(u_n - u)(y))^2 \leq \|\phi(x)\|^2 \left(\int_{\mathbb{R}^d} \|\phi(y)\| |(u_n - u)(y)| d\mu(y) \right)^2$$

Par Cauchy-Schwartz :

$$|\psi_n(x)| \leq \|\phi(x)\|^2 \int_{\mathbb{R}^d} \|\phi(y)\|^2 d\mu(y) \int_{\mathbb{R}^d} |(u_n - u)(y)|^2 d\mu(y)$$

Or, $(u_n - u)_{n \geq 0}$ converge faiblement : c'est une suite bornée dans $L_2(\mu)$. Il existe $M \in \mathbb{R}$ tel que :

$$|\psi_n(x)| \leq M \|\phi(x)\|^2 \int_{\mathbb{R}^d} \|\phi(y)\|^2 d\mu(y)$$

.

Or, $x \in \mathbb{R}^d \rightarrow M \|\phi(x)\|^2 \int_{\mathbb{R}^d} \|\phi(y)\|^2 d\mu(y)$ est intégrable car pour tout $x \in \mathbb{R}^d$, $\|\phi(x)\|^2 = k(x, x)$.

Par convergence dominée,

$$\|T_k u_n - T_k u\|_{L_2(\mu)}^2 = \int_{\mathbb{R}^d} \psi_n(y) d\mu(y) \rightarrow 0$$

Théorème .10: Hilbert-Schmidt

T_k est un opérateur de Hilbert-Schmidt.

Preuve :

T_k est linéaire auto-adjoint continu et compact. Montrons que T_k est défini positif.

Soit $u \in L_2(\mu)$ tel que $u \neq 0$.

$$\langle T_k u, u \rangle_{L_2(\mu)} = \int_{\mathbb{R}^d} \left(\int_{\mathbb{R}^d} k(x, y) u(y) d\mu(y) \right) u(x) d\mu(x)$$

On utilise la décomposition en features map de k :

$$\langle T_k u, u \rangle_{L_2(\mu)} = \left\langle \int_{\mathbb{R}^d} \varphi(x) u(x) d\mu(x), \int_{\mathbb{R}^d} \varphi(y) u(y) d\mu(y) \right\rangle_H = \left\| \int_{\mathbb{R}^d} \varphi(y) u(y) d\mu(y) \right\|_H^2 > 0$$

L'inégalité est stricte car $\int_{\mathbb{R}^d} \varphi(y) u(y) d\mu(y) \neq 0$.

Ainsi, nous pouvons appliquer le théorème : il existe $(\lambda_i)_{i \geq 0}$ une suite de valeurs propres strictement positives décroissante et tendant vers 0 et une base hilbertienne $(u_k)_{k \geq 1}$ de $L_2(\mu)$ formée de vecteurs propres de T_k , telle que :

$$\forall n \geq 0, \quad T_k u_n = \lambda_n u_n$$

Dans $\bar{\mathbb{R}}^+$:

$$\sum_{n \geq 0} \lambda_n^2 = \sum_{n \geq 0} \langle T_k u_n, T_k u_n \rangle_{L_2(\mu)} = \sum_{n \geq 0} \int_{\mathbb{R}^d} T_k u_n(x)^2 d\mu(x)$$

Or,

$$\forall x \in \mathbb{R}^d, n \geq 0, T_k u_n(x) = \langle k(x, \cdot), u_n \rangle_{L_2(\mu)}$$

Donc, d'après l'égalité de Parseval

$$\sum_{n \geq 0} \lambda_n^2 = \int_{\mathbb{R}^d} \sum_{n \geq 0} \langle k(x, \cdot), u_n \rangle_{L_2(\mu)}^2 d\mu(x) = \int_{\mathbb{R}^d} \|k(x, \cdot)\|_{L_2(\mu)}^2 d\mu(x)$$

Comme

$$\int_{\mathbb{R}^d} \|k(x, \cdot)\|_{L_2(\mu)}^2 d\mu(x) = \int_{\mathbb{R}^d} \int_{\mathbb{R}^d} k(x, y)^2 d\mu(y) d\mu(x) \leq \int_{\mathbb{R}^d} \|\phi(x)\|_H^2 d\mu(x) \int_{\mathbb{R}^d} \|\phi(y)\|_H^2 d\mu(y) < +\infty$$

T_k est bien de Hilbert-Schmidt.

Théorème .11: Permutation

Il existe une permutation π de $\mathbb{N}$ telle que :

$$\left(\sum_{i=0}^{\infty} |\lambda_{\pi(i)} - \hat{\lambda}_i|^2 \right)^{1/2} \leq \left(\int_{\mathbb{R}^d \times \mathbb{R}^d} (k(x, y) - \hat{k}(x, y))^2 d\mu(x) d\mu(y) \right)^{1/2} \quad (12)$$

Preuve : Soit $(e_i)_{i \in I}$ une base hilbertienne de $L_2(\mu)$ la norme de Hilbert-Schmidt de l'opérateur s'écrit :

$$\|T\|_{HS}^2 = \sum_{i \in I} \|Te_i\|^2 = \sum_{i, j \in I} \langle Te_i, e_j \rangle^2$$

Soit $D \in \mathbb{N}$, on pose $\hat{k}(x, y) = \frac{1}{D} \sum_{k=1}^D \phi(w_k, x)^T \phi(w_k, y)$ avec $w_1, \dots, w_k$ des variables aléatoires indépendantes de même loi et telles que pour tout $x, y \in \mathbb{R}^d$

$$\mathbb{E} \left(\frac{1}{D} \sum_{l=1}^D \phi(w_l, x)^T \phi(w_l, y) \right) = k(x, y)$$

Nous avons :

$$\|T_k - T_{\hat{k}}\|_{HS}^2 = \sum_{i \in I} \|(T_k - T_{\hat{k}})e_i\|_{L_2(\mu)}^2 = \sum_{i, j \in I} \langle (T_k - T_{\hat{k}})e_i, e_j \rangle^2$$

Donc,

$$\begin{aligned} \|T_k - T_{\hat{k}}\|_{HS}^2 &= \sum_{i \in I} \int_{\mathbb{R}^d} (T_k - T_{\hat{k}})(e_i(x))^2 d\mu(x) \\ &= \sum_{i \in I} \int_{\mathbb{R}^d} \left(\int_{\mathbb{R}^d} (k(x, y) - \hat{k}(x, y)) e_i(y) d\mu(y) \right)^2 d\mu(x) \end{aligned}$$

Or, pour tout $x \in \mathbb{R}^d$, en utilisant l'identité de Parseval :

$$\sum_{i \in I} \left(\int_{\mathbb{R}^d} (k(x, y) - \hat{k}(x, y)) e_i(y) d\mu(y) \right)^2 = \sum_{i \in I} \langle k(x, \cdot) - \hat{k}(x, \cdot), e_i \rangle_{L_2(\mu)}^2 = \|k(x, \cdot) - \hat{k}(x, \cdot)\|_{L_2(\mu)}^2$$

De plus,

$$\|k(x, \cdot) - \hat{k}(x, \cdot)\|_{L_2(\mu)}^2 = \int_{\mathbb{R}^d} (k(x, y) - \hat{k}(x, y))^2 d\mu(y)$$

Ainsi,

$$\|T_k - T_{\hat{k}}\|_{HS}^2 = \int_{\mathbb{R}^d \times \mathbb{R}^d} (k(x, y) - \hat{k}(x, y))^2 d\mu(y) d\mu(x)$$

Nous concluons avec le théorème 3.1.2.

Théorème .12:

$\hat{k}$ et G ont les mêmes valeurs propres.

Preuve : Par définition de $T_{\hat{k}}$, pour tout $f \in L_2(\mu)$:

$$T_{\hat{k}} f = \sum_{j=1}^D \langle \phi_j, f \rangle_{L_2(\mu)} \phi_j.$$

L'image de $T_{\hat{k}}$ est contenue dans $\text{Vect}(\phi_1, \dots, \phi_D)$. Soit $\lambda \neq 0$ une valeur propre de $T_{\hat{k}}$ et f un vecteur propre associé. Alors $f \in \text{Vect}(\phi_1, \dots, \phi_D)$, donc il existe $a = (a_1, \dots, a_D)^\top$ tel que

$f = \sum_{i=1}^D a_i \phi_i$. En substituant dans $T_k f = \lambda f$ et par indépendance linéaire des ϕ_i :

$$\sum_{j=1}^D a_j G_{ij} = \lambda a_i \quad \forall i = 1, \dots, D,$$

soit $G a = \lambda a$. Ainsi λ est valeur propre de G de vecteur propre a .

Perplexité d'un modèle de grand langage

Définition .1: Perplexité d'un modèle de grand langage

Soit un modèle de langage p_θ et une séquence de tokens $x = (x_1, \dots, x_T)$. La perplexité du modèle sur cette séquence est définie par :

$$\text{PPL}(x) = \exp \left(-\frac{1}{T} \sum_{t=1}^T \log p_\theta(x_t \mid x_1, \dots, x_{t-1}) \right)$$

C'est l'exponentielle de l'entropie croisée moyenne par token. Elle correspond à la moyenne géométrique de l'inverse des probabilités assignées par le modèle à chaque token correct, conditionnellement au contexte précédent. Une perplexité de k s'interprète comme le fait que le modèle hésite en moyenne entre k tokens équiprobables à chaque étape de génération.

Divergence de Kullback-Leiber (KL) et top1-agreement

Définition .2: Divergence de Kullback-Leibler

La divergence de Kullback-Leibler entre deux distributions de probabilité discrètes P et Q définies sur un même espace Ω est donnée par :

$$D_{\text{KL}}(P \parallel Q) = \sum_{x \in \Omega} P(x) \log \left(\frac{P(x)}{Q(x)} \right),$$

à condition que $Q(x) > 0$ dès que $P(x) > 0$.

Dans le cas continu, elle s'écrit :

$$D_{\text{KL}}(P \parallel Q) = \int_{\Omega} p(x) \log \left(\frac{p(x)}{q(x)} \right) dx,$$

où p et q désignent les densités associées à P et Q .

Définition .3: Top-1 Agreement

Le *top-1 agreement* entre deux modèles mesure la proportion de positions pour lesquelles les deux distributions prédisent le même token le plus probable. En notant

$$y_P = \arg \max_i P_i, \quad y_Q = \arg \max_i Q_i,$$

le top-1 agreement est défini par :

$$\text{Top1Agreement}(P, Q) = \frac{1}{N} \sum_{k=1}^N \mathbf{1}(y_P^{(k)} = y_Q^{(k)}),$$

où N désigne le nombre total de prédictions comparées et $\mathbf{1}$ la fonction indicatrice.

Validation théorique de l'implémentation du Performer

Metric	Log
Max abs difference on logits	0.058
Mean abs difference on logits	0.0039
Average Cosine similarity	0.999
KL divergence of last token	$3e^{-5}$

TABLE 5 – Comparaison des distributions pour 0/32 têtes performer

En fixant 0/32 têtes d'attention sous architecture Performer, on obtient des distributions quasi équivalentes sur les deux modèles (classique softmax et approché avec 0/32 attention heads). La similarité cos de 0.999 confirme la bonne implémentation du routage vers des têtes attention vs softmax.

Pour les dimensions $N=64$ et $D=64$ fixées, on augmente le nombre de features dans l'étape de sampling ORF. L'erreur décroît avec l'augmentation du nombre de features ce qui confirme que l'approximation implémentée se rapproche de l'architecture classique dans le cas d'un sampling large.




FIGURE 6 – Le modèle approché converge vers le classique softmax pour des grandes dimensions de sampling

Benchmark de la vitesse d'inférence pour la phase Decode

Lors de la phase de génération auto-régressive, chaque nouveau token doit porter son attention sur l'ensemble du contexte précédemment généré et mis en cache. L'attention Softmax possède un coût de décodage de $\mathcal{O}(N \cdot D)$ et le Performer $\mathcal{O}(M \cdot D)$. L'architecture Performer rend le coût de calcul indépendant de la longueur de contexte lorsque l'état intermédiaire est maintenu au cours du décodage. Dans le cas contraire, une recomputation complète conduit à une complexité : $\mathcal{O}(N \cdot M)$

Contexte N	Softmax (ms)	Performer M=256 (ms)	Accélération
64	0.171	0.249	1.39
256	0.095	0.245	0.80
1024	0.091	0.239	0.78
4096	0.292	0.247	2.48

TABLE 6 – Temps de décodage auto-régressif en fonction de la longueur de contexte

Le tableau ci dessus reporte le temps de génération d'un nouveau token en fonction de la taille du contexte déjà accumulé. Les résultats sont brouillés par La latence du Performer reste quasiment constante lorsque la longueur du contexte augmente. Cela s'explique par le fait que l'état accumulé utilisé lors du décodage correspond à une matrice fixe de taille $M \times D$, indépendamment de N . À

l'inverse, l'attention Softmax présente des variations liées aux effets de bande passante mémoire pour des tailles intermédiaires, avant de voir son coût augmenter significativement pour les grands contextes.

L'avantage du Performer apparaît donc principalement dans les scénarios utilisant de longues séquences de contexte.

Stratégie et processus de fine tuning

La progression est pensée comme un entraînement par difficulté croissante :

Phase	Têtes Performer	Paramètres dégelés	LR	Epochs
1	4/32	Q, K seulement	2e-5	2
2	8/32	Q, K, V, O	2e-5	2
3	16/32	Q, K, V, O	1e-5	1
4	32/32	Q, K, V, O	1e-5	1

TABLE 7 – Stratégie de distillation

En phase 1 seules les paramètres Q et K sont dégelés. FAVOR+ change fondamentalement comment les queries et keys interagissent (projection feature map au lieu de dot product). Geler V/O permet de stabiliser les représentations avant de perturber la projection de valeurs par la suite. Le passage progressif via 4, 8, 16 puis 32 permet de donner au modèle le temps d'absorber l'approximation avant de rendre l'approximation davantage grossière. Le taux d'apprentissage (LR) réduit en phase 3 et 4 car la tâche est plus difficile donc la convergence plus fragile.

Fonction de perte

$$\mathcal{L} = 0.5 \times \text{CE}(\text{logits}_{\text{student}}, \text{labels}) + 0.5 \times T^2 \times \text{KL}\left(\frac{\text{logits}_{\text{teacher}}}{T} \parallel \frac{\text{logits}_{\text{student}}}{T}\right) \quad (13)$$

Le terme CE maintient la performance sur le token suivant (objectif LM standard). Le terme KL pousse le student (modèle patché) à reproduire la distribution complète du teacher (TinyLlama original) et pas seulement son argmax. Cela donne un signal de gradient plus riche, notamment sur les tokens de probabilité intermédiaire. $T=2.0$ adoucit les distributions pour que le KL soit plus informatif (soft labels). Le teacher est figé à chaque phase — c'est toujours TinyLlama original qui sert de référence.

Prompts d'évaluation des modèles

1. The history of artificial intelligence begins with the development of the first computers in the 1940s.
2. In mathematics, a prime number is a natural number greater than 1 that has no positive divisors other than 1 and itself.
3. The French Revolution began in 1789 and led to the rise of Napoleon Bonaparte as Emperor of France.
4. Quantum mechanics is a fundamental theory in physics that describes nature at the smallest scales of energy levels.

5. Climate change refers to long-term shifts in global temperatures and weather patterns caused by human activities.
6. The human genome contains approximately three billion base pairs encoding around twenty thousand protein-coding genes.
7. Shakespeare wrote thirty-seven plays and one hundred fifty-four sonnets during his lifetime in the sixteenth century.
8. The theory of relativity introduced by Einstein revolutionized our understanding of space, time, and gravity.
9. Photosynthesis is the process by which plants convert sunlight into chemical energy stored as glucose molecules.
10. The industrial revolution transformed manufacturing processes and led to urbanization across Europe and North America.

Prompts d'évaluation de la perplexité

1. Machine learning is a subset of artificial intelligence that enables systems to learn from data
2. The French Revolution began in 1789 and fundamentally transformed French society and government.
3. Quantum mechanics describes the behavior of matter and energy at the atomic and subatomic levels.
4. Climate change refers to long-term shifts in global temperatures and weather patterns.
5. The human genome contains approximately three billion base pairs of DNA.

Prompts pour l'évaluation qualitative des générations de sortie

1. The history of artificial intelligence begins
2. In mathematics, a prime number is
3. The capital of France is Paris. The Eiffel Tower

Générations complètes par phase

Prompt 1 : *“The history of artificial intelligence begins”*

Teacher (0/32 — softmax)

with the development of the first true computer. The first computer was built by IBM in 1943 and was capable of performing only simple arithmetic operations. However, it was not until the 1950s that significant progress was made in the field of artificial intelligence.

In 1956, American computer scientist John McCarthy introduced the term “artificial intelligence” to describe the study of intelligent machines.

Phase 1 — 4/32 têtes FAVOR+

with the invention of the first computers, which transformed the world of science and technology. The development of the first AI systems was driven by the desire to create machines that could perform complex tasks that were previously impossible for humans to achieve. One of the first successful AI systems was the IBM Watson, which was developed to help doctors diagnose medical conditions.

Phase 2 — 8/32 têtes FAVOR+

with a machine learning algorithm that mimics the way humans learn. This early algorithm was called “Mona Lisa,” and it was first implemented by a team of computer scientists led by Andrew Ng at the University of California, Berkeley. In 1995, a team of researchers at the University of Illinois developed the AlphaGo, a program that outperformed the best human players in the world in a series of games.

Phase 3 — 16/32 têtes FAVOR+

with the invention of the printing press in the 1440s, with the invention of the printing press in the 15th century. The invention of the printing press had a significant impact on the spread of information, allowing the creation of the first printed book in 1445. The invention of the printing press transformed the world of knowledge, allowing the dissemination of information, and the growth of knowledge.

Phase 4 — 32/32 têtes FAVOR+

in the first and other ways of the city.

[illegible]

Prompt 2 : “*In mathematics, a prime number is*”

Teacher (0/32 — softmax)

a number that is greater than 1 and has no positive integer factor other than 1 and itself. The smallest prime number is 2, and the largest prime number is $2^{31} - 1$. A prime number is not a composite number, meaning that it has no positive integer factor other than 1 and itself.

Phase 1 — 4/32 têtes FAVOR+

a whole number that is not divisible by any non-zero integer. In many languages, the term “prime” is used to refer to a non-negative integer, but this is not always true for all languages. For example, in Japanese, the word prime is used to refer to an integer greater than 1.

Phase 2 — 8/32 têtes FAVOR+

a whole number greater than 1 and less than $2n$, where n is a positive integer. [*Suivi de blocs de whitespace dégénérés.*]

Phase 3 — 16/32 têtes FAVOR+

a positive integer that is greater than 1. A prime number is a positive integer that is greater than 1. [...] A prime number is a positive integer that is greater than 1. The first prime number is 2. The second prime number is 3. *[Répété approximativement dix fois.]*

Phase 4 — 32/32 têtes FAVOR+

not very little more than February.

[illegible]

Prompt 3 : “*The capital of France is Paris. The Eiffel Tower*”

Teacher (0/32 — softmax)

is located in Paris. The capital of Italy is Rome. The Colosseum is located in Rome. The capital of Spain is Madrid. The Royal Palace of Madrid is located in Madrid. The capital of Sweden is Stockholm. The Royal Palace of Stockholm is located in Stockholm. The capital of the United States is Washington D.C. The White House is located in Washington D.C. The capital of Australia is Canberra. The Parliament House of Australia is located in Canberra.

Phase 1 — 4/32 têtes FAVOR+

is one of its most famous landmarks. The city of Dubai is famous for its tallest building, the Burj Khalifa. The city of Bangkok, Thailand, is famous for its famous temples, such as Wat Phra Kaew and Wat Arun.

Phase 2 — 8/32 têtes FAVOR+

is the most famous landmark in the city. The Louvre Museum is one of the world's most famous museums. The Arc de Triomphe is a monument in Paris, France. The Notre Dame Cathedral in Paris is a symbol of the Catholic Church. The Louvre Museum is the most famous museum in the world. The Eiffel Tower is the most famous landmark in Paris. *[Répétition en boucle sur ~5 cycles.]*

Phase 3 — 16/32 têtes FAVOR+

is the highest in the world, and it was built in 1882 as the Gare de L'Horloge and was officially opened in 1889. The city is the capital of the region of Auvergne-Charente-Charente-Nouvelle-Aquitaine.

Phase 4 — 32/32 têtes FAVOR+

, ascentrate, and an artwork of the city of the

[illegible]

Références

- [1] Francis BACH. *On the spectrum of kernel matrices (Part I)*. Anglais. Blog post. 2023. URL : <https://francisbach.com/spectrum-kernel-matrices-i/>.

- [2] Djalil CHAFAÏ. *The Hoffman-Wielandt inequality*. Anglais. Blog post. 2011. URL : <https://djalil.chafai.net/blog/2011/12/03/the-hoffman-wielandt-inequality/>.
- [3] Krzysztof CHOROMANSKI et al. « Rethinking attention with performers ». In : *International Conference on Learning Representations*. 2021.
- [4] Tri DAO, Christopher DE SA et Christopher RÉ. « Gaussian quadrature for kernel features ». In : *Advances in Neural Information Processing Systems*. T. 31. 2018.
- [5] Ludwig ELSNER. « On the variation of spectra of matrices ». In : *Linear Algebra and its Applications* 64 (1985), p. 25-34. URL : https://pub.uni-bielefeld.de/download/1776345/2312158/Elsner_075.pdf.
- [6] Purushottam KAR et Harish KARNICK. « Random feature maps for dot product kernels ». In : *Artificial Intelligence and Statistics*. 2012, p. 583-591.
- [7] Quoc LE, Tamás SARLÓS et Alexander SMOLA. « Fastfood : Approximate kernel expansions in loglinear time ». In : *International Conference on Machine Learning*. 2013.
- [8] Frédéric LEGOLL et Pierre LISSY. *Problèmes d'évolution*. Cours de l'ENPC, Février-Juin 2026. 2026.
- [9] Chin-Yew LIN. « ROUGE : A Package for Automatic Evaluation of Summaries ». In : *Text Summarization Branches Out*. ACL. 2004, p. 74-81.
- [10] Alexandra Sasha LUCCIONI, Sylvain VIGUIER et Anne-Laure LIGOZAT. « Power Hungry Processing : Watts Driving the Cost of AI Deployment ? » In : *Proceedings of the 2023 ACM Conference on Fairness, Accountability, and Transparency*. 2023, p. 85-99.
- [11] Duke NGUYEN et al. « Spectraformer : A Unified Random Feature Framework for Transformer ». In : *arXiv preprint arXiv :2405.15310* (2024). DOI : [10.48550/arXiv.2405.15310](https://arxiv.org/abs/2405.15310). URL : <https://arxiv.org/abs/2405.15310>.
- [12] Kishore PAPINENI et al. « BLEU : a Method for Automatic Evaluation of Machine Translation ». In : *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*. ACL. 2002, p. 311-318.
- [13] Ali RAHIMI et Benjamin RECHT. « Random features for large-scale kernel machines ». In : *Advances in Neural Information Processing Systems*. T. 20. 2007.
- [14] REUTERS. « OpenAI's weekly active users surpass 400 million ». In : *Reuters* (fév. 2025). URL : <https://www.reuters.com/technology/artificial-intelligence/openais-weekly-active-users-surpass-400-million-2025-02-20/>.
- [15] Yao-Hung Hubert TSAI et al. « Transformer dissection : An unified understanding for transformer's attention via the lens of kernel ». In : *arXiv preprint arXiv :1908.11775* (2019).
- [16] Ashish VASWANI et al. « Attention is all you need ». In : *Advances in Neural Information Processing Systems* 30 (2017).
- [17] Yunyang XIONG et al. « Nyströmformer : A Nyström-based self-attention approximation ». In : *AAAI Conference on Artificial Intelligence*. 2021.